

先端理工学特別講義

数理・情報・データサイエンス分野の研究活動
ー生成AI，説明可能なAIの研究動向

大分大学 理工学部 理工学科
知能情報システムプログラム
DX人材育成基盤プログラム

行天 啓二

人工知能とは

人工知能(Artificial Intelligence)

コンピュータが人間の知的活動を模倣する技術



機械学習(Machine Learning)

AIを実現するための多様な手法
大量のデータからパターンやルールを発見し、判別や予測などに応用する技術

ニューラルネットワーク(Neural Network)

機械学習の一手法で、脳の神経回路を模倣



深層学習(Deep Learning)

多層のニューラルネットワークを用いた高度な学習技術

ニューラルネットワークとは(1/2)

ニューラルネットワーク

人間の**脳神経系**をモデル化したネットワーク




$$\begin{aligned} x_1w_1 + x_2w_2 + x_3w_3 + x_4w_4 + \dots &\leq \theta \rightarrow y=0 \\ &> \theta \rightarrow y=1 \end{aligned}$$

脳の神経細胞（ニューロン）

ニューラルネットワークとは(2/2)

ニューラルネットワーク

人間の**脳神経系**をモデル化したネットワーク



ニューラルネットワークの歴史

実は長い歴史

1943年	モデル考案	単純な ネットワーク 構造
1940～50年代	様々な学習アルゴリズム提案	限られた 学習方法
1960年代	パーセプトロン流行	
→ 1980年代	ボルツマンマシン流行	
	3層ニューラルネットワーク + 誤差逆伝搬法流行	
→ 2010年代	深層学習技術流行	
→ 2020年代	生成AI技術流行	

3つのブレークスルー

2024年ノーベル物理学賞
ジョン・ホップフィールド
ジェフリー・ヒント

1 つめのブレークスルー(1980年代)

誤差逆伝搬法の実用化

多層ニューラルネットワークの学習が可能

以前から提案されていたが、コンピュータの性能向上とともに実用化

様々な問題点

層の数が多くなると学習が停滞

過学習の発生

(学習したものは覚えられるが、覚えていないものは全くダメ)

ニューロ&ファジィ



ナショナル 電子ジャー炊飯器
ニューロ・ファジィー升炊き



ナショナル ニューロ・ファジィ55
愛妻号洗濯機

<https://jmtty.jp/saga/sale-ele/article-11mm6>

<https://jmtty.jp/chiba/sale-ele/article-lfi92>

より引用

人工知能冬の時代



人工知能は人間を超えるか ディープラーニングの先にあるもの

松尾豊 著

KADOKAWA/中経出版(2015)

書類審査を無事通過した私は、意気揚々と面接に臨んだ。面接の会場では、他の分野の大御所の先生が何人も座っており、その前へひとりプレゼンテーションをした。研究内容について根ほり葉ほり質問を受けた後、先生方から言われた言葉に、私は衝撃を受けた。

「広告なんてくだらないものをするな」

「言葉のネットワークが簡単にできまうぞと言っうな」

そして、最後に浴びせかけられた言葉が極めつけにひどかった。

「あなたたち人工知能研究者は、いつもそうやって嘘をつくんだ」

案の定、その提案は落選した。いま考えてみても、検索エンジンと広告モデルが当たり前になったいまの時代を先取りする研究であらう、悪い提案ではなかったはずだが、当時とはひといめにあつた。学生時代、人工知能の研究者に育てられた自分にとつては、初めての世間の冷たい風をまともに受けた瞬間だった。

「人工知能という言葉を使つてはいけないんだ」

「人工知能というだけで、敵愾心を燃やす人がたくさんいるんだ」

そのとき受けた衝撃は、私が最初に臨んだ研究費の面接の苦い思い出として、いまでも痛烈に心に刻み込まれている。

だが、時代は変わった。

いま、世の中は、人工知能ブームに差しかかっている。ネットのニュースにも、新聞や雑誌、テレビにも、人工知能という言葉が

章を読み終えるまで:20分

「人工知能」という言葉が、いろいろなところで聞かれる。ほんの10年前とは大きな違いである。私が大学院の学生だった1997年から2002年ごろには、人工知能の研究をしているというと、怪訝な顔をされることが多かった。

そして、最後に浴びせかけられた言葉が
極めつけにひどかった。
「あなたたち人工知能研究者は、いつも
そうやって嘘をつくんだ」

意を読み終えるまで:23分

0%

2 つめのブレークスルー (2010年代)

ニューラルネットワークの**深層化**

学習方法の改良

ネットワーク構造の改良

計算機の性能向上

ビッグデータの普及

多くの研究者が注目


TensorFlowやPyTorchなど、様々なフレームワークが登場

オープンソースの普及

A I の応用例 (1/5)

2012年, 画像認識コンペティションILSVRC (Imagenet Large Scale Visual Recognition Challenge)において, SuperVision(トロント大)が, 圧倒的に勝利

位置検出^[1]



[1] https://image-net.org/static_files/files/supervision.pdf

ILSVRC2012

図20 ILSVRC 2012 の結果：タスク1（分類）

ほかの研究所の人工知能がエラー率 26% 台の攻防を繰り返す中、
トロント大学の「SuperVision」が 15%、16% 台とぶっちぎりの勝利

	Team name	Filename	Error (5 guesses)	Description
トロント大学の SuperVision	SuperVision	test-preds-141-146.2009-131-137-145-146.2011-145f.	0.15315	Using extra training data from ImageNet Fall 2011 release
	SuperVision	testpreds-131-137-145-135-145f.txt	0.16422	Using only supplied training data
東大の ISI も 健闘したが	ISI	pred_FVs_wLACs_weighted.txt	0.26172	Weighted sum of scores from each classifier with SIFT +FV, LBP+FV, GIST+FV, and CSIFT+FV, respectively.
	ISI	pred_FVs_weighted.txt	0.26602	Weighted sum of scores from classifiers using each FV.
	ISI	pred_FVs_summed.txt	0.26646	Naive sum of scores from classifiers using each FV.
	ISI	pred_FVs_wLACs_summed.txt	0.26952	Naive sum of scores from each classifier with SIFT+FV, LBP+FV, GIST+FV, and CSIFT+FV, respectively.
	OXFORD_VGG	test_adhocmix_classification.txt	0.26979	Mixed selection from High-Level SVM scores and Baseline Scores, decision is performed by looking at the validation performance
	XRCE/INRIA	res_1M_svm.txt	0.27058	
	OXFORD_VGG	test_finecls_classification.txt	0.27079	High-Level SVM over Fine Level Classification score, DPM score and Baseline Classification scores (Fisher Vectors over Dense SIFT and Color Statistics)
	OXFORD_VGG	test_baseline_classification.txt	0.27302	Baseline: SVM trained on Fisher Vectors over Dense SIFT and Color Statistics
	University of Amsterdam	final-UvA-Isvoc2012test.results.val	0.29576	See text above



人工知能は人間を超えるか
ディープラーニングの先にあるもの

松尾豊 著

KADOKAWA/中経出版 (2015)

より引用

A I の応用例 (2/5)

手書き漢字認識

文字認識の中で、手書き漢字認識は最も難しい問題

従来手法
深層学習導入後

認識率は95%前後
認識率は**98%前後**へ



Fig. 1. Character categories whose recognition rate is 100%.

TABLE VI. DESCRIPTIONS ABOUT SAMPLES WITH CONFIDENCE HIGHER THAN 0.999 BUT RECOGNIZED ERROR

Confidence Interval	[0.99,0.999)	[0.999,0.9999)	[0.9999,1]
#Samples	137791	160136	373658
# incorrectly recognized before correction	824	186	97
#Labeled incorrectly annotated	434	177	97
Accuracy after corrected	99.68%	99.99%	100.00%

学習用データの誤りも発見できるレベル！

(華南理工大 2015) [2]

A I の応用例 (3/5)

碁

コンピュータ囲碁プログラム **AlphaGo** (Google 2015～)

2015年以前は、最強の以後プログラムは、アマチュア有段者レベル

※碁：解を求めるための探索空間が極端に広いため、
人間に匹敵するプログラムを実現するのは難しいとされていた

オセロ < チェス < 将棋 < 碁

2015年 ヨーロッパ王者 樊麾(Fan Hui)に勝利

2016年 世界戦優勝者 李世乭(Lee Sedol)に勝利

2017年 世界トップ棋士柯潔(Ke Jie)に勝利. 人類との対局から引退

A I の応用例 (4/5)

翻訳

2016年11月 Google が 深層学習を導入したGoogle翻訳を公開

原文 The Linux man-pages project documents the Linux kernel and C library interfaces that are employed by user-space programs. With respect to the C library, the primary focus is the GNU C library (glibc), although, where known, documentation of variations on other C libraries available for Linux is also included.

エキサイト翻訳 Linux人ページプロジェクトは ユーザー宇宙計画によって使用されるLinuxカーネルとCライブラリインタフェースを文書化する。Cライブラリについて、Linuxで利用可能な他のCライブラリのバリエーションのドキュメンテーションは、また含まれてwhere知られている けれども、主要なフォーカスはGNU Cライブラリ (glibc) である。

Google翻訳 Linuxのman-pagesプロジェクトは、ユーザー空間プログラムによって採用されているLinuxカーネルとCライブラリのインタフェースについて記述しています。Cライブラリに関しては、主要な焦点はGNU Cライブラリ (glibc) ですが、既知のところでは、Linuxで利用可能な他のCライブラリのバリエーションのドキュメントも含まれています。

賢くなったGoogle翻訳

 Graham Neubig@neubig
翻訳業界関係者で話題になっていますが、**Google翻訳が英日・日英翻訳を新しい翻訳方式（ニューラル翻訳）に変えたようです。精度（特に流暢性）が大幅に向上したと思われるので、ぜひ試してみてください！** translate.google.com
2016-11-11 22:39:30

 V@voluntas
とりあえず RFC 食わせてみたら、**すげー読みやすいぞw**
2016-11-11 23:49:38

 mttkk@mtkk
すごい、まだおかしいところ多いけど以前より全然自然になってる！英語力がアドバンテージじゃなくなる日も近いなー
2016-11-11 23:53:00

 ろうでん@clichtz
すごい めっちゃ自然な日本語
2016-11-12 00:01:01

 こは@cagpie
え、これマジですごくってるんじゃない？
2016-11-12 01:00:44

 ミレン@mirenn00
ますますTOEICの勉強したくなくなるな
2016-11-11 23:59:49

 はーり@Tigerbunny2
あ、たしかに長文投げてあんまり破綻してない、これすごい、ありがたい
2016-11-11 23:49:16

 natu_0710@natu_07_10
N たしかにめっちゃ読みやすくなってる
2016-11-11 23:52:53

 【あちに】@tini_p3
あのギャグみたいなGoogle翻訳は死んでしまったのか...
2016-11-12 00:00:23

 JKのD氏@minami_siki
ほんと、自然言語処理の分野は魔法みたいだわ.....
2016-11-12 00:07:37

 Seikoh Fukuma@doku_f
トレンドでGoogle翻訳が進化したと言うから見てみたが凄いな。もう貧弱な自分の英語力よりも流暢になってる。
2016-11-12 00:52:49

<https://togetter.com/li/1047453> より引用

A I の応用例 (5/5)

生成 A I


画像とテキストの分野で革新的な進化

様々な分野で新たな価値を創出

→ **クリエイティブな作業**の効率化や質の向上が期待

画像生成


- ・ GAN(モントリオール大 2014[3])
Stable Diffusion(ミュンヘン大 2022[4]), ...etc.
- ・ 高品質な画像を自動生成



ピカソ風「最後の晩餐」([4]より引用)

テキスト生成

- ・ **ChatGPT** (OpenAI 2022 (GPT(2018[5]))がベース))
- ・ 高度な自然言語処理能力
- ・ 対話システムや記事作成など多用途



ChatGPT 12+
OpenAI

「仕事効率化」内1位
★★★★★ 4.7 • 13.2万件の評価
無料・アプリ内課金があります

ChatGPTアプリ

[3] I. J. Goodfellow et al.: “Generative Adversarial Nets”, NeurIPS2014.


[4] R. Rombach et al.: “High-Resolution Image Synthesis with Latent Diffusion Models”, CVPR2022, pp.10684–10695.

[5] A. Radford et al.: “Improving Language Understanding by Generative Pre-Training”, 2018.

3 つめのブレークスルー (2020年代)

学習データの**大規模化**

並列処理が可能なモデルの提案
長期記憶が可能なモデルの提案
ネットワークの大規模化




多くの技術者が注目

これらの技術を**容易にシステムに組み込む**技術が提供
あらゆる場面での人工知能技術応用の試み

Transformerの登場[6]

Self-Attention機構による**文脈理解**精度向上
入力の**長さ**に**依存しない**処理構造
並列処理の実現（＝GPUによる高速学習実現）

→で、大量の文章データを学習させると、
とんでもないことに… **ChatGPTの登場**



事前学習と**ファインチューニング**により誰でも使えるA Iへ

事前学習 : 大量のデータを**事前に学習**

ファインチューニング : 目的に応じて少量のデータを**追加で学習**
目的に応じた性能調整

生成 A I とは

学習したデータをもとに、**新しいデータを自動で生成**する A I



従来の A I



文章生成



画像生成



音楽生成




コード生成

生成 A I


生成モデルの原理

学習データの確率分布を学習して
サンプリング



どのようなデータを生成するか
の条件を与えることで、
それに沿ったデータを生成
(条件付き生成)

テキストプロンプト
画像 ...etc.



主な生成モデル

敵対的生成ネットワーク (GAN)

拡散モデル (Diffusion Model)

自己回帰モデル (Autoregressive Model (ex. GPT)) ...他

大規模言語モデル (LLM)

敵対的生成ネットワーク (Generative Adversarial Network)


生成器と識別器が競い合いながら
学習する「敵対的学習」構造

生成器 (Generator)

ノイズからリアルなデータを生成

識別器 (Discriminator)

データが本物か偽物かを判定



©2021 Deep Learning Study

<https://deep-learning-study.net/dcgan/> より引用

画像生成の先駆け



生成例 [7]より引用

[7] T.Karras et al. : "Progressive Growing of GANs for Improved Quality, Stability, and Variation", ICLR, 2018.


拡散モデル (Diffusion Model)

ノイズを加えてデータを徐々に破壊し
逆仮定でノイズから元データを復元


高画質・高精度
GANより安定

テキスト条件付き生成が可能
(Stable Diffusion)

“An oil painting of a space shuttle”



[8] より引用



[9] より引用

- [8] Y. Song et al. : “Score-based Generative Modeling Through Stochastic Differential Equations”, ICLR, 2021.
[9] R. Rombach et al. : “High-Resolution Image Synthesis with Latent Diffusion Models”, CVPR, 2022.

大規模言語モデル (Large Language Model) の出現


巨大なテキストデータを学習して自然言語を理解・生成するモデル

前述のTransformerの出現により…


Self-Attention機構による
長期依存関係を捉える能力の向上

並列処理構造に基づく,
GPU, TPUを用いた大規模学習の実現

パラメータ数が増えても安定して
学習できる拡張性の実現



<https://jalamar.github.io/illustrated-transformer/> より引用



自己回帰モデル (Autoregressive Model)

一つ前までの出力(文脈)に基づいて、
次の単語(トークン)を順に生成

TransformerのDecoderを用いる
ことにより自己回帰的生成を実現


→GPT

文脈を考慮した一貫性のある
データ列を生成

サンプリングで多様な出力を実現



<https://huggingface.co/learn/llm-course/chapter1/4> より引用



[6] より引用

生成 A I の応用例

参考資料

Google Cloud 生成AI活用事例集 (2024年10月版)

<https://inthecloud.withgoogle.com/genai-case-study/dl-cd.html>

人工知能技術の社会実装（バーチャルアシスタント）

株式会社ビットキー

住宅設備の取り扱い説明書を学習
住宅設備に関する内容閲覧や問い合わせ自動化
<https://bitkey.co.jp/newsroom/20211109/>

株式会社スリーシェイク

システム運用に係る助言・参考コード自動生成
 自社スペシャリストたちがより高度な課題に専念
<https://sreake.com/blog/chatgpt-slack-integr>

日本情報通信株式会社

人工知能技術の社会実装（レポー

人工知能技術の社会実装（レポート作成）

株式会社QTnet

SNS上の口コミのうちポジティブなものを収集し、要約して従業員に提示
店舗従業員のモチベーション向上
<https://cloud.google.com/blog/ja/products/ai-machine-learning/the-first-gen-ai-innovation-awards-grand-prize>

株式会社ソニックス

社内ナレッジ・ソースコード・社内議事録を学習させて営業担当者に各種情報を提示

人工知能技術の社会実装（マーケティング）

株式会社NTTデータ

SNSを活用した探索型分析により、生活者視点のマーケティング意思決定を支援する新手法の提案
トレンドの兆し発見から企画書案生成までを実現する「トレンドエクスプローラー」の提供
<https://www.nttdata.com/global/ja/news/release/2024/012601>

人工知能技術の社会実装（検索支援（顧客向け））

株式会社出前館

曖昧な検索キーワードが指定されても関連性の高い商品を提示
<https://www.youtube.com/watch?v=oVoSqtDK9IU>

株式会社ミスミグループ本社

機械加工部品の検索に係り、商品名や型番が不明瞭な検索に対応
<https://xtech.nikkei.com>

Forbes Inc.

同社のニュース記事を対象
<https://media-innovation>

人工知能技術の社会実装（文書管理）

イオンモール株式会社

顧客アンケートを自動要約して業務効率化と戦略的思考を促進
同様の方法でクラウド上に集約された情報を現場とマネジメン
間で共有し、連携を強化
<https://it.impress.co.jp/articles/-/26874>

京都大学医学部附属病院

医療文書作成を効率化し、医師の負担軽減と働き方改革を推進
過去のカルテを参照し、記述内容を標準化することで情報共有
業務効率を向上
<https://www.kuhp.kyoto-u.ac.jp/press/20240603.html>

AI技術の社会実装（コード生成）

トグラント

を活用したプログラム生成ツール「D2AQ」を開発・
 機能や品質評価を備えたD2AQは、自社内での運用を通じ、
 と品質向上を実現
prtimes.jp/main/html/rd/p/0000000002.000089356.html

株式会社

成や言語変換の半自動化
などの古い言語を新しい言語に変換し、過去のプログラムの
一化を回避
[/ascii.jp/elem/000/004/188/4188729/](http://ascii.jp/elem/000/004/188/4188729/)

人工知能技術の社会実装（検索支援（社内向け））

損害保険ジャパン株式会社

照会対応における検索拡張生成導入
誤った回答を許容できない業務について、**回答が正しいか**
・**根拠があるかを提示する技術**を導入
https://www.sompo-japan.co.jp/-/media/SJNK/files/news/2024/20241022_1.pdf?la=ja-JP

東洋建設株式会社

過去の指摘事項・法令データ・災害事例の**検索補助**
チャットボット形式，RAGに対応し，簡単な操作で大幅な検索
時間の短縮を実現
<https://g-gen.co.jp/case-studies/22/>

説明可能な A I (Explainable AI) とは

A I モデルの**意思決定プロセス**や**予測結果**を，人間が理解できる形で**説明・解釈可能にする技術**


なぜ説明可能な A I が必要か？

社会的信頼・透明性の確保

意思決定プロセスが不透明だと，ユーザは
その出力や予測を**信頼できない**

倫理的・法的責任の明確化

A I の決定が偏見や誤りを反映する場合，
倫理的・法的な**説明ができない**




Adversarial Example



x
“panda”
57.7% confidence

$+ .007 \times$



$\text{sign}(\nabla_x J(\theta, x, y))$
“nematode”
8.2% confidence

$=$



$x + \epsilon \text{sign}(\nabla_x J(\theta, x, y))$
“gibbon”
99.3 % confidence



テナガザル！

[10]より引用




・・・本当に大丈夫？

説明可能な A I の分類

Interpretable Models (解釈可能モデル)


比較的簡単かつ**解釈可能なモデルを利用**した A I



[11]より引用

Model Induction (近似モデルによる説明)

ブラックボックス化した A I モデルを
解釈可能なモデルで近似



[12]より引用

Deep Explanation (深層的説明)

アテンションヒートマップを用いて
ブラックボックス化した A I モデルの
判断を視覚化



[13]より引用

[11] S. Park et al. : "Attribute And-Or Grammar for Joint Parsing of Human Pose, Parts and Attributes", PAMI, 2018.

[12] M. T. Ribeiro et al. : "'Why Should I Trust You?': Explaining the Predictions of Any Classifier", KDD, 2016.

[13] R. R. Selvaraju et al. : "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization", ICCV, 2017.

Activation Maximization

ニューラルネットワークの
あるニューロンが
最大限に反応する入力を逆算

処理例

(理解可能な画像に
するために工夫が
必要)





Figure 1. What is encoded by a CNN? The figure shows five possible reconstructions of the reference image obtained from the 1,000-dimensional code extracted at the penultimate layer of a reference CNN[13] (before the softmax is applied) trained on the ImageNet data. From the viewpoint of the model, all these images are practically equivalent. This image is best viewed in color/screen.



入力




このニューロンは
どんな特徴に強く反応する？
(モデルの内的表現の可視化)

[14]より引用

Deep Dream

Activation Maximizationの技術を利用



※すべて <https://github.com/google/deepdream> より引用

Grad-CAM, Grad-CAM++, Score-CAM

A I モデルが**どの領域に注目して判断したか**を可視化

Grad-CAM


出力に対する勾配を利用
どの領域が出力に寄与
したかを可視化

Grad-CAM++

複数の対象がある画像でも可視化

Score-CAM

勾配を用いずに可視化可能・**ノイズ耐性強**



[15]より引用


※CAM = Class Activation Mapping

LIME (Local Interpretable Model-agnostic Explanations)


任意のモデルに対して、
入力に近い局所的な説明モデルを構築

どの特徴が予測に影響したかを把握

ニューラルネットワークに限らず
どんなモデルに対しても適用可能



[12]より引用




※ <https://www.nri-secure.co.jp/blog/explainable-ai> より引用 (一部改変)

説明可能な A I の応用例

医用画像診断支援

肺炎の診断




Grad-CAM

LIME

[16]より引用
(一部改変)

自動運転における 意思決定の説明

交通環境の
理解



通行可能

生物

車

[17]より引用
(一部改変)


...etc.

[16] S.Rajaraman et al. : "Visualizing and explaining deeplearning predictions for pneumoniadetection in pediatric chestradiographs", SPIE, 2019.

[17] S.Kolekar et al. : "Explainable AI in Scene Understanding for Autonomous Vehicles in Unstructured Traffic Environments on Indian Roads Using the Inception U-Net Model with Grad-CAM Visualization", Sensors, 2022.

とあるポスト

「テスラは縦に積まれた人間を認識できない」



※ <https://x.com/9m/status/1819656997635285028> より引用 (一部改変)

生成 A I と説明可能な A I の関係と今後の課題

生成 A I における生成過程の説明可能性

「なぜそのような文章を生成したのか？」

「なぜそのような画像を生成したのか？」

→ 偏見・ハルシネーション (事実でない出力) への対応

今後の課題

多様な出力に対する説明

長く複雑な生成過程における説明

説明の信頼性と有用性のバランス

➡ “Explainable Generative AI” へ