

談話会発表 論文紹介



Realguard: A Lightweight Network Intrusion Detection System for IoT Gateways


Xuan-Ha Nguyen , Xuan-Duong Nguyen , Hoang-Hai Huynh , and Kim-Hung Le
Faculty of Computer Networks and Communications, University of Information Technology,
Ho Chi Minh City 70000, Vietnam Submission received: 3 November 2021 / Accepted: 27
December 2021 / Published: 7 January 2022 Computer Science and Engineering This article
belongs to the Special Issue **Cybersecurity in the Internet of Things**

所属 : 情報基盤システム学研究室
発表者 : DAVAAKHUU UNDARMAA
指導教員 : 池部 実 講師 吉崎 弘一 教授
発表日 : 2025年11月27日
会場 : セミナー1(第三講義棟)

目次

- 研究背景・目的
- Realguardとは
- 検知手法
- 評価結果
- まとめ・今後の課題

研究背景・ How Many IoT Devices Are There?




2025年までに接続された IoT デバイスの数は 198 億に達すると予測されており、2034年までには 406 億に倍増すると見込まれています。しかし、2025年時点で、前年から平均 11.86% 増加し、世界中で 177 億件の IoT 接続があると報告されています。

今後もこの勢いは続くと予想されており、2034年までに接続された IoT デバイスの数は 406 億に急増すると推定されています。



Zero to
Minimum
Built-In Security



(Top-3 Threats)

1. Exploits (脆弱性を利用した攻撃)
2. パスワード関連攻撃 / (Password-related attacks / Phishing)
3. マルウェア (Malware、ウイルス、ボットネットなど)

研究背景・Lightweight) ソリューションの必要性

- → 軽量 (Lightweight) ソリューションの必要性

低リソース消費:

- CPU や RAM が限られた IoT デバイスでも動作可能


特性に基づく検知:

- IoT プロトコルや各デバイスの通常の動作に基づき
攻撃を検知

低遅延・リアルタイム検知:

- トラフィックが多い IoT ネットワークでも高速でリアルタイムに検知可能

研究背景 ・ What is Machine Learning?



人間が経験から学ぶように、コンピュータもデータから学んで予測や判断ができるようになります。

例：


メールフィルター：迷惑メール（spam）を判別する。

顔認識システム：カメラで撮った写真から人を認識する。

自動運転車：カメラやセンサーの情報をもとに自動で運転する

Machine Learning（機械学習）とは、コンピュータが明確なプログラムを書かなくても、データや経験から自動的に学習し、パターンを見つけたり、将来の結果を予測したりする技術です。

Machine learning types
(Convolutional Neural Network) CNN,
and (Long Short-Term Memory) LSTM , DNN (Deep Neural Network)



特徴（特長）


- 空間的特徴の抽出に優れている
- 画像や映像など、2次元データに強い
- 局所的なパターン（エッジ・形状）を自動的に学習

利点（メリット）

高精度な画像認識が可能
モデル構造が比較的単純で学習が速い

欠点（デメリット）

時系列的な依存関係を扱うのが苦手
ネットワークトラフィックなど、時間変化のあるデータには不向き



特徴（特長）

長期的な時系列依存関係を保持できる
過去の情報を「記憶」しながら学習


利点（メリット）

時間的特徴を持つデータ（トラフィック、ログなど）に強い
長期依存関係を効果的に捉えることが可能

欠点（デメリット）

パラメータ数が多く、学習に時間がかかる
計算リソースを多く消費（リアルタイム処理に不向き）

Why choose (Deep Neural Network)



なぜ層のニューロン数が減少するのか？
(128 → 96 → 64 → 32 → 16)

層が深くなるにつれて、ネットワークは不要な情報を削ぎ落とし、最も本質的な特徴だけを残して最終的な判断を行います

DNN とは何か？

Deep Neural Network、深層ニューラルネットワーク）は、ディープラーニングに基づく人工ニューラルネットワークです。複数の隠れ層（hidden layer）を用いてデータの複雑な構造やパターンを認識し、正常データと異常データを区別する能力を持ちます。

問題点（課題）

- ニューロンが多い → 精度は高いが、学習が遅く、過学習のリスクあり
- ニューロンが少ない → 学習は速いが、精度が低い

解決策（ソリューション）

「**Growing Approach**」を採用

小さいネットワークから開始
層やニューロンを段階的に追加しながら性能を最適化

子どもの成長と学び（Growing Approachとの比較）

なぜ層のニューロン数が減少するのか？
(128 → 96 → 64 → 32 → 16)

たとえば：

100個の特徴量 → 情報がとても多い



128ニューロン → すべての情報を考慮



96ニューロン → 重要な特徴を抽出



64ニューロン → より絞り込む



32ニューロン → 主要な特徴を保持



16ニューロン → 最も重要な情報のみ残す



11クラス → 最終的な分類結果


Network Intrusion Detection System (NIDS)

NIDSとは何か？

Network Intrusion Detection

System () は、ネットワークのトラフィックを読み取り、監視し、攻撃、マルウェア、不正アクセスなどの異常な動作を検出するシステムです。

How does an IoT Gateway work



IoT (Internet of Things) 環境で使用するデバイスをネットワークに接続し、データを中央サーバーやクラウドに送信する仲介デバイスです。

役割


- IoT センサーやアクチュエーターのデータを収集統合処理
- ネットワークプロトコル (MQTT、CoAP、HTTP など) を通じて IoT デバイスとサーバーを接続
- 場合によっては、一次処理、フィルタリング、セキュリティチェックを実施

特徴:

データのフィルタリング、暗号化、圧縮が可能

CPU や RAM が少ない IoT デバイス向けに最適化

ネットワーク全体の効率的運用とセキュリティを確保



Protocol Translation: デバイスとサーバー間のデータを適切なプロトコルに変換

Edge Computing: 事前処理や計算をゲートウェイで実行

Security: 暗号化、ファイアウォール、攻撃からの保護

Scalability: ネットワークの拡張に対応可能

信頼性 (Reliability) : 安定したデータ転送を確保

経済性 (Economical) : 低コストで IoT システムを運用可能

目次

- 研究背景・目的
- Realguardとは
- 検知手法
- 評価結果
- まとめ・今後の課題

目的

主な目標:IoT ゲートウェイ上で動作する 軽量かつ高精度な攻撃検知システムを構築する.

具体的な目標

科学的貢献

競合システムより優れる
実運用に適した設計

高精度

99%以上の精度
11種類の攻撃を検知
誤警報を最小化

技術的解決策:

軽量アーキテクチャ
リアルタイム検知
限られたリソースで
動作可能

目次


- 研究背景・目的
- Realguardとは
- システム構成
- 検知手法
- 評価結果
- まとめ・今後の課題

■ Realguardとは

Realguard は、ディープラーニングに基づくネットワーク侵入検知システム（NIDS）です。


IoT 環境において、CPU や RAM が限られたデバイス上でも動作できるように設計されています。

- ネットワークトラフィックの監視
- 特徴量（features）の抽出
- DNN を用いた攻撃の検知



セキュリティ監視システム (NIDS)

- カメラ監視 → POC (観測)
「人を検知しました」
- 記録・ログ作成 → FEC (情報収集)
「背が高い・黒い服・不審な動き...」
- 上位監視 (AI解析) → ADC (DNN)
「この人物は泥棒か？従業員か？」
「95%の確率で“泥棒”です！」
- アクション実施 → AMC (対策)
「警察へ通報！ドアをロック！」



1. Packet Observation Component (POC)
→ ネットワークトラフィックを継続的に監視し、パケットのメタデータを取得します。

2. Feature Extraction Component (FEC)
→ トラフィックの統計を計算し、feature vector に変換します。
→ Damped Incremental Statistics アルゴリズムを用いて、高速かつ低リソースで動作。

3. Attack Detection Component (ADC)
→ DNN (Deep Neural Network) を使用してリアルタイムで攻撃を検知。
→ 攻撃の有無だけでなく、種類 (DoS、Scan など) も識別。

Action Manager Component (AMC)
→ 攻撃が検知された場合、事前設定に基づき適切な対応を実施：ログの保存, トラフィックのブロック, 管理者へのメール通知

Realguard は 4 つの主要コンポーネントで構成されている。

目次

- 研究背景・目的
- Realguardとは
- 検知手法
- 評価結果
- まとめ・今後の課題

Algorithm1 Update

昨日の朝ごはん、覚えていますか

1分 → 100% 覚えている
1時間 → 80% 覚えている
1日 → 30% 覚えている
1か月 → 5% ほぼ忘れる

Algorithm 1 は“人間の記憶”と同じ仕組みで動く

Algorithm 1: Update $IV_{i,\alpha}$

Input : $IV_{i,\alpha}, x_C, t_C, r_j$

Output: $IV_{i,\alpha}$

- 1 $\delta \leftarrow d_\alpha(t_C - t_L)$
 - 2 $IV_{i,\alpha} \leftarrow (\delta w, \delta LSI, \delta SSI, \delta SR_{ij}, t_C)$
 - 3 $IV_{i,\alpha} \leftarrow (w + 1, LSI + x_C, SSI + x_i^2, SR_{ij} + r_i r_j, t_C)$
 - 4 return $IV_{i,\alpha}$
-

入力 (Input):

$IV_{i,\alpha}$ = 以前の情報 (古い統計)

x_C = 新しく到着したパケットのサイズ

t_C = 現在の時刻

r_j = パケットの速度

出力 (Output):

$IV_{i,\alpha}$ = 更新された情報

step1: $\delta \leftarrow da(tc - tL)$

時間経過を考慮して減衰係数 (Damping weight) を計算する

数学的表現:

• t_C = 現在の時刻 (例: 10:00:05)

• t_L = 最後に更新した時刻 (例: 10:00:00)

• 経過時間 = $t_C - t_L = 5$ 秒

$\delta = da(5) = e^{(-\lambda \times 5)}$

Algorithm1 Update

Step2: $IV_{i,\alpha} \leftarrow (\delta w, \delta LSI, \delta SSI, \delta SR_{ij}, t_c)$

古い情報に δ を掛けて重みを減少させる

以前の $IV_{i,\alpha}$: 減衰係数: $\delta = 0.9$ (1秒経過)

• $w = 100$ (総パケット数) $w = 0.9 \times 100 = 90$

• $LSI = 5000$ (総サイズ) $LSI = 0.9 \times 5000 = 4500$

• $SSI = 25000$ (二乗和) $0.9 \times 1200 = 1080$

• $SR_{ij} = 1200$ (速度の相関) $0.9 \times 1200 = 1080$

以前: 「100個のパケットを観測した」

現在: 「90個のパケットを覚えていて、10個のパケットは忘れた」

step3: $IV_{i,\alpha} \leftarrow (w+1, LSI+x_c, SSI+x_c^2, SR_{ij}+r_i r_j, t_c)$

新しいパケットの情報を加える

新しいパケット:

$x_c = 512$ バイト (新しいパケットのサイズ)

$r_i = 10$ パケット/秒 (速度)

$r_j = 8$ パケット/秒

更新後の値:

$w = 90 + 1 = 91$ (パケット数が増加)

$LSI = 4500 + 512 = 5012$ (総サイズが増加)

$SSI = 22500 + 512^2 = 22500 + 262144 = 284644$

$SR_{ij} = 1080 + (10 \times 8) = 1080 + 80 = 1160$

$t_c = 10:00:05$ (現在時刻)

Algorithm 1: Update $IV_{i,\alpha}$

Input : $IV_{i,\alpha}, x_c, t_c, r_j$

Output: $IV_{i,\alpha}$

1 $\delta \leftarrow d_\alpha(t_c - t_L)$

2 $IV_{i,\alpha} \leftarrow (\delta w, \delta LSI, \delta SSI, \delta SR_{ij}, t_c)$

3 $IV_{i,\alpha} \leftarrow (w+1, LSI+x_c, SSI+x_c^2, SR_{ij}+r_i r_j, t_c)$

4 **return** $IV_{i,\alpha}$

DDoS攻撃 = 数秒で大量のパケット
→ アルゴリズム1は即座に検知

通常トラフィック = 徐々に到着
→ 古い情報は忘れられる

最新の異常のみが検出される

データセット (Datasets)

使用したデータセット:

実験では CIC-IDS2017 データセットを使用した。

このデータセットは、多種のサイバー攻撃トラフィックを含み、ディープラーニングモデルの学習に適している。

データ収集の期間:

2017年7月3日午前9時から7月7日午後5時まで収集。

合計 51.1 GB のデータと、13種類のネットワークトラフィック（正常1種、攻撃12種）を生成。

目次

- 研究背景・目的
- Realguardとは
- 検知手法
- 評価結果
- まとめ・今後の課題

評価指標 / Evaluation Metrics

分かりやすい例：医師の診断

100人が検査に来ました：

- 40人：実際に病気
- 60人：健康

医師の診断結果：

- 38人を病気と正しく診断（TP） True positives
- 2人の病気を見逃した（FN） False positives
- 55人を健康と正しく判定（TN） True negatives
- 5人を誤って病気と判定（FP） False negatives



Realguardの性能評価方法

$$TPR = \frac{TP}{TP + FN}$$

$$TPR = 38 / (38 + 2) = 38 / 40 = 0.95 = 95\%$$

$$FPR = \frac{FP}{FP + TN}$$

$$FPR = 5 / (5 + 55) = 5 / 60 = 0.083 = 8.3\%$$

$$ACC = \frac{TP + TN}{TP + FP + TN + FN}$$

$$ACC = (38 + 55) / (38 + 5 + 55 + 2) = 93 / 100 = 0.93 = 93\%$$

100人のうち93人を正しく判定
7人を誤って判定

医師の 精度は93%！

40人の患者のうち38人を検出
2人の患者を見逃した
医師は 患者の95%を正しく検出できた

60人の健康な人のうち55人を正しく判定
5人の健康な人を誤って患者と判定
医師は 健康な人の8.3%を誤診した！

二値分類 (Binary-class) 検知




図3 + 表4
システムはネットワークトラフィックを「Normal」と「Abnormal」の2クラスに分類する。

Realguard の結果

TPR (True Positive Rate) = 99.66% → 攻撃を正しく検知する能力

FPR (False Positive Rate) = 0.40% → 誤警報の割合

Accuracy = 99.64% → 全体の正確性

ポイント:
Realguard は他のシステムより優れた性能を示す (TPRが最も高く、FPRは最小ではないがバランスが良い)。

Realguard は 8つの競合システム（NB-SVM、DT-EnSVM、DBN など）と比較された。
二値分類（Binary-class）検知の結果

(%)	Realguard	NB-SVM	DT-EnSVM	DBN	PSO+LSTM-RNN	PSO+DNN	XGB	AE+ANN
TPR	99.66	99.46	99.15	99.00	98.68	97.58	97.40	95.81
FPR	0.40	3.00	4.00	2.10	0.16	0.28	12.00	1.23
ACC	99.64	98.92	98.46	98.24	98.83	97.85	91.36	98.18

Realguard: TPR = 99.66%（最も高い）


 FPR = 0.40%（PSO+LSTM-RNN よりやや高い）

ACC = 99.64%（最も高い）

主要指標:

- TPR (True Positive Rate): 攻撃を正しく検知した割合
- FPR (False Positive Rate): 誤警報の割合
- ACC (Accuracy): 全体の正確性

Multi-class attack detection



システムは 11種類の攻撃（DoS、FTP-Patator、SSH-Patator など）をそれぞれ検知。平均 TPR = 99.57%（非常に良好な結果）

課題

DoS Hulk: TPR = 98.45%（1.52% が「Normal」と誤分類）

• Botnet ARES: TPR = 98.46%（1.34% が「Normal」と誤分類）

なぜ誤分類が発生したのか？

DoS Hulk 攻撃: 正常なパケットも送信される（ただし大量に送信）

→ 通常の動作に似て見える

Botnet 攻撃: 攻撃中にパケットが均等に分散される

→ 正常トラフィックに似て見える

(%)	Realguard	MLP	CNN-MCL	XGB	RF	SVC	ANN	LSTM	E-ML	REP Tree
TPR Normal	99.60	99.66	x	99.85	99.93	98.89	99.73	99.69	x	x
TPR Botnet	98.46	91.39	95.19	x	64.45	79.18	38.36	35.81	46.47	47.76
TPR DoSSlowhttpstest	99.48	99.75	91.50	94.45	99.36	83.65	98.82	98.64	93.84	75.36
TPR DoSGoldenEye	99.98	99.98	98.71	99.27	99.76	99.91	99.08	97.62	67.57	66.43
TPR DoSslowloris	99.52	99.85	97.96	91.62	99.14	98.04	98.27	97.07	97.76	92.73
TPR DoSHulk	98.45	97.54	99.10	99.92	99.85	93.36	99.73	99.02	96.78	92.22
TPR FTP-Patator	99.92	99.99	99.77	x	99.94	99.95	99.62	99.68	99.64	99.18
TPR SSH-Patator	99.92	99.95	98.16	x	99.75	99.42	98.30	96.61	99.91	100.00
TPR Heartbleed	99.98	99.99	x	100.00	x	99.97	x	x	100.00	100.00
TPR DDoS	100.00	100.00	99.19	x	99.94	99.98	99.91	99.88	99.88	99.79
TPR PortScan	99.94	99.28	99.86	x	99.95	99.39	99.81	99.92	99.88	99.88
TPR (Avg)	99.57	98.85	97.72	97.52	96.21	95.61	93.16	92.39	90.17	87.33
FPR (Overall)	0.04	0.06	0.23	0.24	0.24	0.20	0.63	0.79	1.15	4.84
ACC (Overall)	99.93	99.89	99.46	99.54	99.86	99.64	99.58	99.57	96.67	93.40

主要指標

- TPR (True Positive Rate):** 攻撃を正しく検知した割合
- FPR (False Positive Rate):** 誤警報の割合
- ACC (Accuracy):** 全体の正確性



Realguard Runtime Performance

	Realguard	Kitsune	RF	LSTM
CPU (%)	36.0	33.8	76.8	47.6
RAM (MB)	114.5	156.3	180.3	143.1

Realguard:

- 学習速度: 6,000 パケット/秒
- 処理速度: 88,200 パケット/秒

Kitsune [23]:

- 学習速度: 1,100 パケット/秒 (5.5倍遅い!)
- 処理速度: 37,300 パケット/秒 (2.4倍遅い!)

Ahmim et al. [24]:

- 学習速度: 200 パケット/秒 (30倍遅い!)
- 処理速度: 17,600 パケット/秒 (5倍遅い!)

ポイント:

Realguard は Raspberry Pi 上で 2倍高速に動作する)。

目次

- 研究背景・目的
- Realguardとは
- 検知手法
- 評価結果
- まとめ・今後の課題

まとめ

Realguard という IoT ゲートウェイ向けの攻撃検知システムを提案します。
このシステムは 10種類の攻撃を99%以上の精度 で検知可能で、Raspberry Pi のようなリソース制限のあるデバイス上でも リアルタイムに動作 する。

実験結果は、システムが競合システムと比較して 処理速度、精度、リソース使用量 の面で優れていることを示しています。
これは単なるラボでの検証にとどまらず、実際のIoT環境で利用可能な実践的なソリューション です。

